

CUSTOMER LIFETIME VALUE

klasterizacija

SAUSAU projektni zadatak

Opis projekta

Cilj ovog projekta je kreiranje modela uz pomoć mašinskog učenja koji klasterizuje komitente prema njihovoj dugoročnoj vrijednosti za kompaniju (CLV), na osnovu njihovih potreba i transakcija u kupovini.

U izradi projekta podrazumijevamo kompletan postupak čišćenja i pretprocesiranja transakcionih podataka, račuanje RFM metrike (Recency, Frequency, Monetary) za svakog komitenta, te primjenu K-Means algoritma za nenadgledano grupisanje komitenata u segmente niske, srednje i visoke CLV vrijednosti. Nakon klasterizacije, izvršena je eksplorativna analiza segmenata.

Pošto K-Means ne omogućava direktnu klasifikaciju novih, prethodno neviđenih komitenata, implementiran je nadgledani klasifikator KNN (a zatim i SVM radi poređenja) koji uči granice klastera dobijene K-Means algoritmom i omogućava predviđanje segmenta za novog komitenta na osnovu njegovih RFM vrijednosti.

Na kraju su izvedeni zaključci proistekli iz izrade projekta, te naravno i prijedlozi za dalji rad i unaprijeđenje modela.

Struktura projekta

```
CLV/
├── data/
│   ├── raw/           # online_retail_II.xlsx, synthetic_high_clv.csv
│   └── processed/      # rfm_clean.csv, rfm_train.csv, rfm_test.csv, rfm_labeled.csv, scaler.pkl
├── models/            # kmeans_model.pkl, knn_model.pkl
├── src/
│   ├── data_preparation.py # učitavanje, čišćenje, RFM izračunavanje
│   ├── train.py           # skaliranje, Elbow metod, K-Means klasterizacija
│   ├── evaluate.py        # tabela i vizualizacija segmenata
│   └── predict.py         # KNN klasifikator za predikciju segmenta
├── results/
│   ├── figures/          # elbow_plot.png, scatter, bar chart, confusion matrix
│   └── metrics/          # segments_table.csv, segments_profiles.csv, segment_map.pkl, knn_izvjestaj.xlsx
├── app.py              # Streamlit aplikacija za predikciju
├── README.md
└── requirements.txt
```

Preprocesiranje

Skup podataka Online Retail II učitani su iz dva Excel sheet-a koji pokrivaju period od decembra 2009. godine do decembra 2011. godine, i spojeni su u jedinstven dataset zajedno sa sintetičkim podacima Synthetic High CLV. Dataset sadrži transakcione podatke veleprodajne kompanije: broj fakture, šifru i opis proizvoda, količinu, datum fakture, cijenu, ID komitenta i državu.

Na početku je izvršeno čišćenje skupa podataka:

- Uklanjanje redova kojima nedostaje vrijednost u koloni Customer ID, jer je identifikator komitenta neophodan za računanje RFM metrike.
- Uklanjanje otkazanih narudžbi, identifikovanih preko broja fakture koji počinje 'C' (cancelled) (npr. C536379).
- Uklanjanje redova sa negativnim ili nultim vrijednostima u kolonama Quantity i Price, koje predstavljaju greške u unosu ili povratu robe
- Atributi StockCode i Description nisu direktno korišteni u modelu, već isključivo za agregaciju transakcija po komitentu. Atribut Country nije korišten jer nam geografska lokacija komitenta ne znači za RFM analizu.

Nakon čišćenja, za svakog komitenta izračunata je RFM metrika:

- **Recency** – broj dana od posljednje kupovine u odnosu na referentni datum (dan nakon posljednje transakcije u datasetu)
- **Frequency** – broj faktura komitenta
- **Monetary** – ukupna potrošnja (zbir proizvoda količine i cijene svakog artikla)

Eksplorativna analiza podataka (EDA)

Nakon računanja RFM metrike, dataset sadrži 6678 komitenata sa tri obilježja, Recency, Frequency i Monetary.

Metrika	Min	Sredina	Mean	Max
Recency (dani)	1	96	201.3	739
Frequency (fakture)	1	3	6.3	398
Monetary (£)	2.95	898.9	3018.6	608821.7

Većina komitenata kupuje rijetko i troši relativno malo, dok manji broj komitenata generiše izuzetno veliku potrošnju. Ovo je tipično za veleprodajni B2B (Business-to-Business) oblik poslovanja, gdje nekoliko velikih klijenata čini veliki dio prihoda.

Ključno:

- Monetary ima ekstremno veliki raspon (od 2.95 £ do 608821.7 £) što potvrđuje potrebu za skaliranjem prije primjene K-Means algoritma, jer bi bez skaliranja ova dimenzija dominirala računanjem euklidskog prostora.
- Frequency je takođe disbalansirana, većina komitenata ima samo 1-3 fakture, dok manjina kupuje desetinama ili stotinama puta
- Nakon inicijalne klasterizacije, uočeno je da je segment High CLV izrazito malobrojan (0.3% komitenata), što je realno da mali broj klijenata generiše veliki dio prihoda.
- Radi balansiranijeg prikaza segmenata i robusnije evaluacije klasifikatora, dataset sam proširio sintetičkim transakcijama za

dodatne komitente sa profilom High CLV (visoka frekvencija, nedavna aktivnost i velika potrošnja), čime je njihov udio povećan na oko ~12%.


Skaliranje (StandardScaler) je primijenjeno tek nakon podjele podataka na trening i test skup kako bi se izbjeglo curenje informacija iz test skupa u proces treniranja.

Modelovanje i izbor metrike

Problem segmentacije komitenata je nenadgledani problem (klasterizacija), jer ne postoje unaprijed poznate oznake CLV segmenta. Odabran je K-Means algoritam, jer pronalazi prirodne grupe komitenata na osnovu udaljenosti u RFM prostoru.

Odabir broja klastera:

Korišten je Elbow metod – za K od 2 do 10 izračunat je WCSS (Within-Cluster Sum of Squares) na trening skupu. Optimalni K je odabran automatski, elbow metod pronalazi tačku najveće promjene nagiba WCSS krive.




Mapiranje klastera u CLV segmente:

K-Means dodjeljuje brožčane oznake klasterima (0,1,2,...) koji nemaju semantičko značenje. Da bi se klasteri mapirali u nazive Low/Mid/High CLV, izračunat je kompozitni RFM skor po klasteru:


$$\text{CLV_Score} = -\text{Recency} + \text{Frequency} + \text{Monetary} \text{ (skalirane vrijednosti)}$$

Recency je invertovan jer manja vrijednost (nedavna kupovina) doprinosi većoj CLV vrijednosti, dok veće vrijednosti Frequency i Monetary direktno doprinose. Klaster sa najnižim skorom dobija oznaku Low CLV, a sa najvišim High CLV.



CLV_Segment	Broj_kupaca	Recency	Frequency	Monetary	Postotak
Very Low CLV	778	2.06	-0.43	-0.37	11.7
Low CLV	1496	0.84	-0.41	-0.36	22.4
Mid CLV	3581	-0.6	-0.32	-0.34	53.6
High CLV	435	-0.81	1.77	1.7	6.5
Very High CLV	388	-0.82	3.3	3.36	5.8

Tabelarni prikaz za svaki segment sa njegovim brojem kupaca, prosječnim RFM vrijednostima (skaliranim) i njihovim udjelom u ukupnoj bazi.



Klasifikacija novih komitenata:

Pošto K-Means ne omogućava direktnu predikciju za novog komitenta bez ponovnog treniranja modela na cijelom skupu, implementiran je nadgledani klasifikator će vršiti klasifikaciju novih komitenata.

Model	Tačnost (test skup)
-------	---------------------

KNN (k=5)	99.5%
-----------	-------

SVM	99.1%
-----	-------

Oba klasifikatora postižu skoro identičnu tačnost, što potvrđuje da su klasteri dobro geometrijski odvojeni u skaliranom RFM prostoru – granice između segmenata su jasne, pa oba algoritma, bez obzira na različit pristup, uspijevaju da ih nauče bez greške, ali sam se ipak opredijelio za KNN klasifikator.

K-Means je treniran isključivo na trening skupu (80% komitenata). Test skup (20%) je korišćen samo za predikciju kako K-Means, tako i KNN/SVM

klasifikatora, čime je obezbjeđena realna procjena generalizacije na nove, neviđene komitente.

Podešavanje hiperparametara

K-Means: Broj klastera (K) je određen automatski uz pomoć elbow metoda.

KNN: Korišteno je 5 susjeda, dovoljno veliki da smanji uticaj šuma u podacima, a dovoljno mali da ne izgubi lokalne granice između klastera.

SVM: Korišten je RBF (Radial Basis Function) kernel sa parametrom $C=1.0$. Omogućava modeliranje nelinearnih granica između klasa, dok parametar C kontroliše balans između širine margine i tolerancije na greške na trening skupu.

Oba klasifikatora postižu tačnost veću od 99% bez dodatnog podešavanja, dobro odvojeni klasteri su učinili zadatak klasifikacije relativno jednostavnim za oba modela.

Analiza rezultata predikcije

KNN klasifikator ($k=5$) ostvario je ukupnu tačnost od 99.5% na test skupu od 1336 komitenata, što je izuzetno visok rezultat. Segmenti definisani K-Means algoritmom su dobro razdvojeni u prostoru, što je omogućilo modelu da postigne ovako visoke performanse. Model pouzdano identifikuje kupce bez značajnijeg rizika od lažno pozitivnih klasifikacija. Mid CLV i High CLV segmenti su prepoznati u potpunosti – nijedan kupac iz ovih kategorija nije propušten. Jedini uočeni nedostatak je nešto niži odziv za Very High CLV segment, gdje je propušten mali broj najvrijednijih kupaca. Performanse na test skupu su u skladu sa rezultatima na trening podacima, što govori u prilog dobre generalizacije i odsustva prekomjernog prilagođavanja.


KNN Klasifikator – Opšte metrike

Metrika	Vrijednost	Napomena
Tačnost modela	99.5%	Na test skupu (20% podataka)
Broj train primjera	5,342	80% ukupnih kupaca
Broj test primjera	1,336	20% ukupnih kupaca
Broj susjeda (K)	5	KNN hiperparametar

Izveštaj po klasama – Precision, Recall, F1

Klasa	Precision	Recall	F1-Score	Support
0	0.9972	1.0000	0.9986	717
1	1.0000	0.9647	0.9820	85
2	1.0000	0.9881	0.9940	168
3	0.9933	0.9933	0.9933	297
4	0.9583	1.0000	0.9787	69
Ukupna tačnost	0.9948			1336

Matrica konfuzije – KNN klasifikator



Odabir najznačajnijih atributa

Model koristi samo 3 atributa – Recency, Frequency i Monetary, koji predstavljaju minimalan skup obilježja specifično odabran za problem procjene vrijednosti komitenta. Sve tri dimenzije nose komplementarnu informaciju o ponašanju komitenta (kada, koliko često, koliko troši), pa nije bilo potrebe za dodatnom redukcijom dimenzionalnosti.

Doprinos svake od tri RFM dimenzije ukupnoj CLV procjeni vidljiv je kroz kompozitni skor korišten za mapiranje klastera – sve tri dimenzije ravnopravno učestvuju u određivanju da li je komitent Low, Mid ili High CLV.

Deployment

Model je izvezen (knn_model.pkl, scaler.pkl, segment_map.pkl) i korišćenje je omogućeno kroz Streamlit aplikaciju (app.py), gdje korisnik unosi Recency, Frequency i Monetary vrijednosti novog komitenta i u realnom vremenu dobija predviđeni CLV segment (Low/Mid/High CLV) sa odgovarajućom interpretacijom.

O aplikaciji

Ova aplikacija koristi KNN klasifikator za predikciju CLV segmenta kupca.

Ulazni parametri:

- **Recency:** Broj dana od posljednje kupovine
- **Frequency:** Ukupan broj kupovina
- **Monetary:** Ukupna potrošnja u £

Izlaz:

- **Low CLV** (niska vrijednost)
- **Mid CLV** (srednja vrijednost)
- **High CLV** (visoka vrijednost)

Deploy

Customer Lifetime Value Segment Predictor

Unesite podatke o kupcu da biste predviđeli njegov CLV segment.

Modeli uspješno učitani

Recency (dana)

Frequency (broj kupovina)

Monetary (£)

20

12

256.97

Predvidi segment

Rezultat predikcije

Mid CLV

Ovaj kupac spada u srednje vrijedan segment.

Rezultati i zaključci

- K-Means algoritam je uspješno grupisao komitente u tri segmenta na osnovu RFM metrike, sa mapiranjem klastera u CLV nazive preko kompozitnog skora.
- Oba klasifikatora (KNN i SVM) postižu tačnost preko 99% na test skupu, što potvrđuje da su K-Means klasteri geometrijski dobro odvojeni u skaliranom RFM prostoru.
- Originalni dataset je imao izrazito disbalansiran High CLV segment (0.3%), što je realan odraz veleprodajnog poslovanja, ali je ograničavalo robusnost evaluacije; dataset je proširen sintetičkim podacima radi balansiranije distribucije.
- Recency mora biti invertovan u kompozitnom skoru jer manja vrijednost (nedavna aktivnost) doprinosi većoj CLV vrijednosti komitenta.
- Skaliranje (StandardScaler) je neophodno prije K-Means klasterizacije jer Monetary ima znatno veći numerički raspon od Recency i Frequency, što bi bez skaliranja dovelo do dominacije ove dimenzije u računanju rastojanja.

Preporuke za unaprijeđenje modela

- Uključiti dodatne attribute ponašanja (npr. prosječna vrijednost narudžbe, sezonalnost kupovine, raznovrsnost kupljenih proizvoda) koji bi mogli preciznije razložiti segmente
- Optimizacija hiperparametara
- Balansiranje klasa dodavanjem novih sintetičkih podataka.