

MotoGP DNF Prediktor

Predikcija ishoda trke primenom masinskog učenja
Binarna klasifikacija: Završio (0) / Odustajanje — DNF (1)

SAUSAU 2026 — Projekat iz Masinskog učenja

Student: Nikola Lukic RA47-2023

Jul 2026

1. Uvod

Ovaj projekat se bavi predikcijom ishoda MotoGP trke — da li će vozač završiti trku (Završio) ili odustati (DNF — Did Not Finish). Problem je formulisan kao binarna klasifikacija sa jakim disbalansom klase: svega ~10.9% trka se završava DNF-om, dok ~89.1% vozača završava trku.

Cilj projekta je da se na osnovu informacija dostupnih PRE starta trke (staza, vozač, tim, konstruktor, godina, redni broj trke u sezoni) predviđi da li će vozač odustati. Ovo je izazovan problem jer su DNF događaji retki i teško predvidivi bez informacija sa same trke (brzina, vreme, pozicija), koje se ne smeju koristiti zbog data leakage-a.

1.1 Skup podataka

Glavni dataset (FILTERED_ROWS.csv) obuhvata 56.396 redova iz perioda 1949-2022. godine, sa 15 originalnih kolona. Nakon filtriranja (samo MotoGP i 500cc klasa), dataset se smanjuje na 14.944 reda. Dopunski podaci iz Qualifying.csv (2022-2025) koriste se za izvlačenje dodatnih karakteristika staza.

1.2 Specifikacija problema

- Tip problema: Binarna klasifikacija (Završio=0, DNF=1)
- Metrika uspeha: Recall (DNF) — false negative (propusten DNF) je skup
- Izazovi: jak disbalans klase, data leakage opasnost, ogranicene pre-race informacije

2. Pocetno preprocesiranje podataka

2.1 Nedostajuće vrednosti i anomalije

Proverom nedostajucih vrednosti utvrđeno je da kolone number (56% missing) i speed (41% missing) imaju veliki broj nedostajucih vrednosti. Ove kolone su svakako uklonjene u kasnijim koracima iz drugih razloga (data leakage i redundantnost). Ostale kolone nemaju znacajan broj nedostajucih vrednosti.

2.2 Filtriranje kategorija

Iz originalnog dataseta sa vise takmicarskih kategorija (MotoGP, 500cc, Moto2, Moto3, MotoE), zadržane su samo MotoGP (od 2002. godine) i 500cc (prethodna najvisa klasa, 1949-2001). Ove dve kategorije predstavljaju ekvivalentan nivo takmicenja i imaju slicne karakteristike u pogledu DNF obrazaca. Nakon filtriranja, dataset broji 14.944 reda.

2.3 Kreiranje target varijable

Target varijabla Status_Zavrsetka se kreira iz originalne kolone position po pravilu: position > 0 => Završio (0), position <= 0 => DNF (1). Vrednost 0 oznacava da vozac nije startovao, a negativne vrednosti oznacavaju odustajanje u odredjenom krugu.

2.4 Uklanjanje data leakage kolona

Data leakage je ozbiljan problem u vremenskim predikcijama. Kolone koje su poznate tek NAKON zavrsetka trke MORAJU biti uklonjene pre treniranja modela. U suprotnom, model bi dobio lazno dobre rezultate koristeći informacije koje u stvarnom svetu ne bi bile dostupne pre trke.

Uklonjene data leakage kolone:

- position — pozicija na kraju trke (iz nje se izvodi target)
- points — broj osvojenih poena (poznat tek nakon trke)
- speed — prosečna brzina tokom trke (poznata tek nakon trke)
- time — ukupno vreme trke (poznato tek nakon trke)

2.5 Uklanjanje redundantnih kolona

Sledeće kolone su uklonjene kao redundantne ili nepotrebne:

- rider — numericki ID vozaca (redundantno sa rider_name)
- number — broj motocikla (56% missing, ne utice na ishod)
- country — zemlja vozaca (vozac vec identifikuje sebe)
- category — sve su MotoGP/500cc nakon filtriranja (konstantno)


2.6 Enkodiranje podataka

Kategoricke varijable (shortname, circuit_name, rider_name, team_name, bike_name) enkodirane su TargetEncoder-om. Za razliku od standardnog LabelEncoder-a ili OneHotEncoder-a, TargetEncoder enkodira svaku kategoriju prosečnom vrednoscu target varijable za tu kategoriju, sto daje znatno vise informacija tree-based modelima. Numericke varijable su skalirane StandardScaler-om (mean=0, std=1).

3. Eksplorativna analiza skupa (EDA)


3.1 Distribucija target varijable

Dataset je izrazito neuravnotežen: 13.318 trka je završeno (89.1%), dok je samo 1.626 trka završeno DNF-om (10.9%). Ovaj disbalans zahteva posebne tehnike — u ovom projektu koriscen je SMOTE (Synthetic Minority Oversampling Technique) za balansiranje klasa na 60/40 odnos pre treniranja modela.



3.2 Korelaciona analiza

Korelacionom analizom numerickih atributa sa target varijablom uocene su sledece najjace korelacije: Track_DNF_Rate (0.181), Team_DNF_Rate (0.178), year (0.173), Bike_DNF_Rate (0.152). Ovi atributi pokazuju da su istorijski obrasci (DNF stopa staze, tima i konstruktora) najbolji prediktori DNF-a. Pojedinačni numericki atributi nemaju izrazito jake korelacije sa targetom (najvisa je ~0.18), sto ukazuje na kompleksnost problema — DNF zavisi od kombinacije vise faktora.



3.3 Boxplot analiza po klasama

Boxplotovi izvedenih feature-a po klasama (Završio vs DNF) pokazuju da DNF klasa ima nešto više prosečne vrednosti za većinu feature-a (posebno za Team_DNF_Rate i Track_DNF_Rate), ali distribucije se znatno preklapaju. Ovo potvrđuje da nema jednostavnog pravila za razdvajanje klasa — potrebni su kompleksniji modeli.

4. Odabir i treniranje modela

4.1 Pregled probanih pristupa

Tokom projekta testirano je vise pristupa resavanju problema. U nastavku je dat pregled svih probanih metoda sa kratkim opisom i razlogom zasto su neki odbaceni:

XGBoost Standalone	SMOTE 60/40 + threshold 0.80	FN=20, Rec=91.8%	Solidan baseline, polazna tacka
Cost-sensitive	Sample weight + cost scorer (FN/FP=5:1)	Poboljsan F1, gori recall	Cost optimizuje ukupni trosak, ne minimalni FN
Anomaly detection	Isolation Forest + One-Class SVM	F1~0.17, Recall~13%	DNF nije outlier u feature space-u — klase se preklapaju
SVM tuning	GridSearchCV + razni thresholdi	Losa kalibracija verovatnoca	SVM nije pogodan za ovaj problem
Stacking	XGB+LR+RF+MLP + meta-LR	Recall=25.8%	Meta-learner zagladjuje predikcije, gubi ekstremne DNF
Ensemble OR	XGBoost + LR, OR logika	FN=16, Rec=93.4%	OR logika hvata DNF koje jedan model propusti — znatno bolje
Platt kalibracija	CalibratedClassifierCV za oba modela	FN=9, Rec=96.3%	XGBoost Brier score sa 0.62 na 0.33 — kljucno poboljsanje
Feature selection	SHAP + RFECV, 16->12 feature-a	Recall pao na 89.8%	I slabi feature-i doprinose — zadrzano svih 16
Bagging K-voting	5x XGBoost + 5x LR, bootstrap, K=2 konsenzus	FN=6, Rec=97.5%	Najbolji model — diverzitet kroz bootstrap + konsenzus

4.2 Tri produkcijska modela


Nakon svih eksperimenata, izdvojena su tri modela koja daju najbolje rezultate. Svi modeli su trenirani na SMOTE 60/40 podacima sa 16 feature-a (5 kategorickih TargetEncoded + 11 numerickih StandardScaled). Evaluacija je vrsena na test skupu od 2.242 reda (1.998 Zavrsio, 244 DNF).

4.3 Model 1: XGBoost Standalone (SMOTE 60/40)

Prvi model je jednostavan XGBoost klasifikator treniran na SMOTE 60/40 podacima. Korisceni su hiperparametri: learning_rate=0.01, max_depth=6, n_estimators=200, scale_pos_weight=8. Threshold za DNF predikciju je 0.80.

Rezultat: Ovaj model predstavlja baseline sa kojim se porede svi napredniji modeli. Propuska 20 od 244 DNF-a (8.2%), uz 1.536 laznih alarma.

FN	FP	TP	Recall	Prec	F1	DNF%
20	1536	224	91.8%	12.7%	0.224	78.5%




4.4 Model 2: OR Ensemble Kalibrisan

Drugi model koristi dva nezavisna modela — XGBoost i LogisticRegression — sa OR logikom: DNF se predviđa ako BILO KOJI od dva modela predvidi DNF. Oba modela su kalibrisana Platt scaling-om (CalibratedClassifierCV, method='sigmoid', cv=5).


Razlog za kalibraciju: XGBoost-ove sirove predict_proba vrednosti su lose kalibrisane (Brier score 0.62, sve verovatnoce > 0.80). Platt scaling popravlja Brier score na 0.33, dajuci realne verovatnoce koje omogucavaju precizniji threshold tuning. Pragovi su postavljeni na XGB=0.35, LR=0.30.

Rezultat: OR logika u kombinaciji sa kalibracijom smanjuje broj propustenih DNF-ova sa 20 na svega 9 (poboljsanje od 55%). Ovo je postignuto jer LR hvata DNF-ove koje XGBoost propusta i obrnuto.

FN	FP	TP	Recall	Prec	F1	DNF%
9	1600	235	96.3%	12.8%	0.226	81.8%



Kalibracione krive pokazuju koliko su verovatnoce modela pouzdane. Idealna kalibracija znaci da predvidjena verovatnoca od X% odgovara stvarnoj ucestalosti DNF-a od X%. Kriva koja prati dijagonalu (isprekidana linija) oznacava savrsenu kalibraciju.




4.5 Model 3: Bagging Ensemble sa K-voting-om (FINALNI)

Treci i finalni model koristi bagging (bootstrap aggregating) sa K-voting konsenzusom. Iz originalnog trening skupa generise se 5 bootstrap uzoraka (nasumicno izvlacenje SA VRACANJEM, ista velicina kao original). Na svakom bag-u se trenira po jedan XGBoost i jedan LR (oba Platt-kalibrisana), sto daje ukupno 10 nezavisnih modela.


K-voting: Svaki od 10 modela glasa (DNF=1, Zavrasio=0) na osnovu thresholda 0.35. Konacna odluka: DNF ako bar K=2 modela glasa za DNF. Ovo filtrira pojedinačne random greske — ako jedan model nasumicno pogresi, drugi ga ispravljaju.

Rezultat: Bagging sa K=2 daje najbolji rezultat od svih modela — samo 6 propustenih DNF-ova od 244 (2.5%). U odnosu na pocetni XGBoost baseline (FN=20), ovo je poboljsanje od 70% u broju propustenih DNF-ova.

FN	FP	TP	Recall	Prec	F1	DNF%
6	1625	238	97.5%	12.8%	0.226	82.6%



Grafik performansi po K vrednostima: Kako K raste (zahteva se vise glasova za DNF), Recall opada (vise propustenih DNF-ova), ali Precision raste (manje lazni alarma). K=2 predstavlja optimalan balans.



5. Poredjenje modela i evolucija performansi

5.1 Uporedna tabela

Model	FN	FP	Recall	Prec	F1
1. XGBoost Standalone	20	1536	91.8%	12.7%	0.224
2. OR Kalibrisan	9	1600	96.3%	12.8%	0.226
3. Bagging K=2 (finalni)	6	1625	97.5%	12.8%	0.226

5.2 Evolucija kroz iteracije

Projekat je prosao kroz vise iteracija poboljsanja. Svaka iteracija je donela konkretno smanjenje broja propustenih DNF-ova (FN):

Faza	Pristup	FN	FP	Recall	Poboljsanje
1	XGBoost Standalone	20	1536	91.8%	--
2	+ Ensemble OR voting	16	1553	93.4%	-4 FN
3	+ Threshold tuning	10	1600	95.9%	-6 FN
4	+ Platt kalibracija	9	1600	96.3%	-1 FN
5	+ Bagging K-voting	6	1625	97.5%	-3 FN

Od pocetnih 20 propustenih DNF-ova do svega 6 u finalnom modelu — smanjenje false negative za 70%. Cena ovog poboljsanja je porast false positive sa 1.536 na 1.625 (povecanje od 5.8%). S obzirom da je u ovom problemu false negative (propusten DNF) znatno skuplji od false positive (lazni alarm), ovaj trade-off je prihvatljiv.

6. Podesavanje hiperparametara

Za svaki model, hiperparametri su optimizovani kroz GridSearchCV sa stratified 5-fold cross-validacijom. Skoring metrika je bio F1-score (za balansiranje preciznosti i odziva), a za cost-sensitive modele koriscen je custom cost scorer.

6.1 XGBoost hiperparametri

Optimalni hiperparametri za XGBoost (pronadjeni GridSearch-om):

- learning_rate = 0.01 (najmanji testiran, daje stabilnije konvergenciju)
- max_depth = 6 (dovoljno duboko za kompleksne interakcije, bez overfitting-a)
- n_estimators = 200 (dovoljno stabala za konvergenciju gradijenta)
- scale_pos_weight = 8 (daje 8x vecu tezinu DNF klasi pri racunanju gradijenta)

6.2 LogisticRegression hiperparametri

- C = 10 (umerena regularizacija)
- class_weight = 'balanced' (automatski balansira tezine klase)
- max_iter = 2000 (dovoljno iteracija za konvergenciju)

6.3 Bagging hiperparametri

- Broj bagova = 5 (dovoljan diverzitet, prihvatljivo vreme treniranja)
- Kalibracioni CV unutar bag-a = 3 folda
- Threshold po modelu = 0.35
- Default K = 2 (optimalan konsenzus — rezultati za sve K su u metrics_by_K.csv)

7. Odabir najznacajnijih atributa

7.1 SHAP analiza


SHAP (SHapley Additive exPlanations) vrednosti su korisne za odredjivanje doprinosa svakog feature-a predikciji modela. SHAP analiza je izvršena na XGBoost modelu (kao tree-based model, podržava TreeSHAP).

Najznacajniji atributi prema kombinovanoj SHAP + Permutation importance analizi:

1. rider_name — identitet vozača nosi najviše informacija (neki vozači imaju značajno višu DNF stopu od drugih)
2. year — godina trke (starije trke imaju drugačije DNF obrasce)
3. team_name — neki timovi su pouzdaniji od drugih
4. Team_DNF_Rate — istorijska DNF stopa tima
5. Track_DNF_Rate — istorijska DNF stopa staze

Najslabiji atributi (niska SHAP vaznost, negativna permutation importance):

- shortname (−0.08): redundantan sa circuit_name, uklanjanje poboljšava F1
- Quali_Spread, Quali_Top6_Gap, Quali_Time_Std: veoma niska vaznost
- Season_Phase: marginalan doprinos



7.2 Eksperiment sa redukovanim skupom atributa

Pokusano je uklanjanje 4 najslabija atributa (shortname + 3 Quali feature-a), smanjujući broj feature-a sa 16 na 12. Međutim, recall je opao sa 96.3% na 89.8% — iako su ovi feature-i slabi, ipak doprinose detekciji dodatnih DNF-ova. Zaključak: za ovaj problem (gde je FN prioritet), bolje je zadržati sve feature-e.

8. Deployment modela

8.1 Streamlit aplikacija

Finalni model (Bagging K=2) je deployovan kroz Streamlit web aplikaciju. Aplikacija omogućava interaktivno testiranje modela kroz intuitivni korisnički interfejs. Aplikacija se pokreće komandom:

```
streamlit run app/app.py
```

Funkcionalnosti aplikacije:

- Biranje staze, vozača, tima, konstruktora, godine i rednog broja trke
- Slider za K parametar (1-10): minimalan broj glasova za DNF
- Slider za threshold (0.0-1.0): prag verovatnoće po modelu
- Gauge prikaz verovatnoće DNF-a
- Indikatori rizika (istorijski DNF rate, DNF rate tima, itd.)
- 5 preset scenarija za brzo testiranje (Marquez Jerez, Rossi Mugello...)
- Informacije o tome koliko je od 10 bagged modela glasalo za DNF

8.2 Struktura projekta

Projekat je organizovan po principima čistog koda:

src/	— pipeline skripte (data_load, data_cleaning, preprocessing)
production/	— produkcijski modeli (svaki u svom folderu)
models/	— istrenirani modeli (.pkl)
results/	— metrike, grafikoni, matrice konfuzije
app/	— Streamlit deployment aplikacija
experiments/	— svi eksperimentalni pokusaji (10 foldera)
docs/	— dokumentacija
data/	— sirovi i procesirani podaci

9. Zaključak

9.1 Postignuti rezultati

Projekat je uspesno implementirao sistem za predikciju DNF-a u MotoGP trkama. Kroz iterativni proces poboljšanja, broj propustenih DNF-ova (false negative) smanjen je sa pocetnih 20 na svega 6 od 244 test DNF-a — poboljšanje od 70%. Finalni recall iznosi 97.5%, sto znaci da model hvata skoro sve stvarne DNF-ove.

9.2 Ključni nalazi

- OR logika (vise modela, bilo koji predvidi DNF) je superiorna za minimizaciju FN
- Platt kalibracija verovatnoca je neophodna za XGBoost (Brier score sa 0.62 na 0.33)
- Bagging sa K-voting konsenzusom dodatno filtrira random greske pojedinačnih modela
- DNF je inherentno tesko predvideti sa samo pre-race informacijama — cak i najbolji model ima nisku preciznost (12.8%)
- Data leakage je kritican — kolone sa post-race informacijama moraju biti uklonjene
- Feature-i sa niskom vaznoscu ipak doprinose — za FN-prioritet, bolje je zadržati sve

9.3 Ogranicenja i buduci rad

Glavno ogranicenje modela je niska preciznost (12.8%) — 87% DNF predikcija su lazni alarmi. Ovo je posledica fundamentalne tezine problema: sa samo pre-race informacijama, tesko je precizno razdvojiti trke koje ce se završiti DNF-om od onih koje nece.

Potencijalni pravci za poboljšanje:

- Grid position (startna pozicija) — ako bi bili dostupni za ceo dataset
- Vremenska prognoza za dan trke (kisa povecava DNF stopu)
- Pouzdanost motora po modelu i godini
- Broj padova vozaca u tekucoj sezoni

9.4 Doprinosi asistenta (vestacka inteligencija)

U izradi ovog projekta koriscen je AI asistent (OpenCode/Claude) za:

- Generisanje inicijalnog koda pipeline-a i modela
- Predlaganje i implementaciju razlicitih ML pristupa
- Debugging i optimizaciju hiperparametara
- Objasnjenje koncepata (bootstrap, Platt scaling, SHAP)
- Generisanje dokumentacije

Sav kod je pregledan, testiran i prilagodjen od strane studenta. Sve odluke o izboru modela, thresholda i arhitekture su donete na osnovu eksperimentalnih rezultata i konsultacija sa asistentom.