

PROJEKAT: PREDVIĐANJE ISHODA TRKE U MOTOGP ŠAMPIONATU

Tip problema: Binarna klasifikacija (Predviđanje kategorije/klase)

1. Opis i cilj projekta

Projekat se fokusira na primenu mašinskog učenja u analitici vrhunskog motorsporta. Cilj modela je da na osnovu parametara poznatih pre samog početka trke (uslovi na stazi, karakteristike vozača, performanse motocikla i istorijska statistika) klasifikuje da li će određeni vozač uspešno završiti trku i ostvariti plasman, ili će doživeti pad, odustajanje ili tehnički kvar (DNF - Did Not Finish). Ovakav model ima praktičnu primenu u simulacijama strategije timova i proceni rizika tokom trkačkog vikenda.

2. Izvor i struktura skupa podataka (Dataset)

Projekat će koristiti javno dostupan skup podataka sa Kaggle platforme:

- **Naziv seta:** *MotoGP Race Results* (autor: Amal Salilan)
- **Link do podataka:** <https://www.kaggle.com/datasets/amalsalilan/motogpresultdataset>

Podaci obuhvataju specifičnosti staze, vozača, timova i istorijskih sezona. Radi potencijalnog poboljšanja modela, postojeći skup podataka se može unaprediti sa novijim dopunama:

- **Link do dopunjenog seta:**
<https://www.kaggle.com/datasets/sammee/motogp-race-results-2022>

Kategorija	Naziv varijable (Karakteristika)	Tip podatka	Opis
Kontekst trke	circuit_name / shortname	Kategorički	Specifična lokacija i naziv staze na kojoj se trka održava (npr. Jerez, Assen, Mugello).
	year / sequence	Numerički (Diskretni)	Sezona i redni broj trke u kalendaru (indikator faze šampionata i kumulativnog zamora).
Vozač i tim	rider_name	Kategorički	Identitet vozača (omogućava mapiranje individualnog stila i

Kategorija	Naziv varijable (Karakteristika)	Tip podatka	Opis
			sklonosti riziku).
	team_name / bike_name	Kategorički	Naziv tima i konstruktora motocikla (npr. Ducati, Honda, Yamaha), što definiše mehaničku pouzdanost i performanse.
Inženjering karakteristika	Istorijski DNF Rate	Numerički (Kontinualni)	Izvedena karakteristika: procenat odustajanja/padova konkretnog vozača na posmatranoj stazi u prethodnim trkama.
Ciljna promenljiva	Status_Zavrsetka (izvedeno iz position)	Kategorički (Binarni)	Klasa 0: Vozač je završio trku (ostvaren numerički plasman). Klasa 1: Vozač je odustao (oznake Ret, NC, DNF u izvornom setu).

3. Predloženi algoritmi i metodologija

U okviru projekta izvršiće se poređenje sledećih klasifikacionih modela kako bi se utvrdila optimalna arhitektura:

- **Logistička regresija (Logistic Regression):** Služi kao osnovni (baseline) statistički model za binarnu klasifikaciju.
- **Random Forest Classifier:** Algoritam zasnovan na stabalima odlučivanja, pogodan za rukovanje kombinacijom kategoričkih i numeričkih podataka i detekciju nelinearnih zavisnosti.
- **XGBoost / Gradient Boosting:** Napredne metode ansambla koje optimizuju funkciju gubitka i pružaju visoku preciznost na tabelarnim strukturama podataka sa izraženom klasnom neravnotežom.

4. Evaluacione metrike

S obzirom na to da je broj uspešno završenih trka prirodno veći od broja odustajanja (klasna neuravnoteženost), performanse modela neće se ocenjivati isključivo kroz ukupnu tačnost (Accuracy). Koristiće se:

- **Matrica konfuzije (Confusion Matrix):** Za detaljan uvid u greške modela.
- **Precision (Preciznost) i Recall (Odziv):** Za analizu tačnosti pozitivnih predikcija i sposobnosti pronalaženja svih relevantnih instanci.
- **F1-Score:** Kao harmonična sredina, sa posebnim naglaskom na Recall za Klasu 1, jer je primarni cilj modela da tačno prepozna situacije visokog rizika od pada/odustajanja.

5. Očekivani izlaz (Target / Label)

Izlazni podatak iz modela biće binarnog tipa (0 ili 1) i predstavljaće konačni ishod trke za svakog pojedinačnog vozača:

- **Klasa 0 (Završio trku):** Označava da je vozač uspešno prošao kroz cilj i ostvario zvaničan plasman.
- **Klasa 1 (Pad / Odustajanje - DNF):** Označava da vozač iz bilo kog razloga nije završio trku (pad, izletanje sa staze, tehnički kvar ili diskvalifikacija).

6. Dokumentovanje rezultata

Po završetku treniranja i testiranja modela, rezultati će biti detaljno dokumentovani i prikazani kroz:

- **Grafički prikaz matrice konfuzije (Confusion Matrix):** Za vizuelnu identifikaciju tačnog broja ispravno i pogrešno klasifikovanih padova i završenih trka.
- **Uporednu tabelu performansi:** Gde će se za sva tri testirana modela (Logistic Regression, Random Forest, XGBoost) uporediti vrednosti za Accuracy, Precision, Recall i F1-Score, kako bi se jasno argumentovao izbor najboljeg modela.
- **Grafikon važnosti karakteristika (Feature Importance):** Koji će prikazati koji od 5 ulaznih atributa (npr. istorija vozača, tip motocikla ili specifičnost staze) ima najveći matematički uticaj na rizik od odustajanja.